Propensity score matching: módszer, alkalmazások és korlátok

[TODO: Név 1] ([TODO: NEPTUN], [TODO: név1@uni-corvinus.hu])
[TODO: Név 2] ([TODO: NEPTUN], [TODO: név2@uni-corvinus.hu])
[TODO: Név 3] ([TODO: NEPTUN], [TODO: név3@uni-corvinus.hu])

2026. október 13.

1. Bevezetés

A közgazdaságtan egyik alapvető célja különböző beavatkozások (*treatment*) okozati hatásának, az átlagos kezelési hatásnak (*Average Treatment Effect*, ATE) a mérése. A standard megoldás a randomizált kontrollált kísérlet (*randomized controlled trial*, RCT), ahol a kezelés kiosztása véletlenszerű, így a kezelt és a kontrollcsoport várhatóan minden megfigyelt és megfigyelhetetlen jellemzőjében megegyezik. A gyakorlatban azonban sokszor csak megfigyeléses adatok állnak rendelkezésre, ahol a kezelés felvétele nem véletlen, hanem a résztvevők saját döntésén vagy egyéb tényezőkön múlik.

Ilyenkor kiválasztási torzítás (*selection bias*) lép fel, a kezelésre és a kimenetelre egyaránt ható zavaró változók (*confounder*-ek) miatt. Ha egyszerűen összehasonlítjuk a kezelt és a nem kezelt csoport átlagos kimenetelét, torzított eredményt kapunk, mert a különbség egy része a csoportok eredendő különbségeiből fakad. A regressziós kontroll sok változó esetén nehézkes (a dimenzió átka, *curse of dimensionality*). A *propensity score matching* (PSM) ezt úgy kezeli, hogy a confounder-eket egyetlen változóba, a kezelés valószínűségébe sűríti, és e szerint teszi összehasonlíthatóvá a kezelt és a kontroll megfigyeléseket.

2. Módszertan

2.1 Potenciális kimenetelek és a szelekciós torzítás

Minden egyénre ($i = 1, \dots, N$) adott a $T_i \in \{0, 1\}$ kezelési indikátor, a megfigyelt confounderek $X_i \in \mathbb{R}^p$ vektora, valamint két potenciális kimenetel, $Y_i(1)$ és $Y_i(0)$. A megfigyelt kimenetel

$$Y_i = T_i\, Y_i(1) + (1 - T_i)\, Y_i(0).$$

A célparaméterek az átlagos kezelési hatás, illetve a kezeltekre vonatkozó átlagos kezelési hatás (*Average Treatment Effect on the Treated*, ATT):

$$\mathrm{ATE} = \mathbb{E}\big[Y_i(1) - Y_i(0)\big], \qquad \mathrm{ATT} = \mathbb{E}\big[Y_i(1) - Y_i(0) \mid T_i = 1\big].$$

A megfigyeléses adatokon számolt naiv különbség torzított:

$$\begin{aligned}\Delta &= \mathbb{E}[Y_i \mid T_i = 1] - \mathbb{E}[Y_i \mid T_i = 0] \\ &= \underbrace{\mathbb{E}\big[Y_i(1) - Y_i(0) \mid T_i = 1\big]}_{\mathrm{ATT}} + \underbrace{\mathbb{E}\big[Y_i(0) \mid T_i = 1\big] - \mathbb{E}\big[Y_i(0) \mid T_i = 0\big]}_{\text{szelekciós torzítás}}.\end{aligned}$$

A naiv becslés tehát csak akkor egyezik meg az ATT-vel, ha a szelekciós torzítás nulla. Ez randomizált kísérletben garantált, megfigyeléses adatokban a confounderek miatt általában nem teljesül.

2.2 Azonosító feltevések

A megfigyeléses adatokból oksági hatás becsléséhez két feltevés szükséges:

1. **Feltételes függetlenség** (*unconfoundedness*): $\big(Y_i(1), Y_i(0)\big) \perp\!\!\!\perp T_i \mid X_i$.
2. **Közös tartomány** (*common support/overlap*): $0 < \mathbb{P}(T_i = 1 \mid X_i = x) < 1$ minden x-re.

A propensity score a kezelés valószínűsége a megfigyelt tulajdonságok mellett:

$$e(x) = \mathbb{P}(T = 1 \mid X = x).$$

Rosenbaum–Rubin-tétel (1983): ha teljesül a feltételes függetlenség, akkor

1. (kiegyensúlyozó tulajdonság, *balancing property*) $X \perp\!\!\!\perp T \mid e(X)$,
2. $\big(Y(1), Y(0)\big) \perp\!\!\!\perp T \mid e(X)$.

Vagyis elég az $e(X)$ skalárra kondicionálni, nem kell az egész X vektorra.

2.3 Becslés és párosítás

A propensity score becslése osztályozási feladat, leggyakrabban logisztikus regresszióval:

$$e(X_i) = \mathbb{P}(T_i = 1 \mid X_i) = \frac{1}{1 + \exp\big(-(\beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki})\big)} \in (0, 1).$$

Ezután minden kezelt egyént párosítunk egy hasonló score-ú nem kezelttel. A két leggyakoribb algoritmus a legközelebbi szomszéd (*nearest-neighbour*) és a kernel matching. A párosítás után ellenőrizni kell, hogy a minta valóban kiegyensúlyozott lett-e, azaz a párosítás eltüntette-e a csoportok közötti különbségeket az alapjellemzőkben. Ha igen, a párosított csoportok kimeneteleinek különbsége becsli a kezelés okozati hatását.

3. Szakirodalmi példák

1. Cikk: Dehejia, R. H., & Wahba, S. (1999). *Causal effects in nonexperimental studies: Reevaluating the evaluation of training programs.*

Azt vizsgálták, hogy egy amerikai államilag támogatott munkaerőpiaci tréning növeli-e a résztvevők jövőbeli jövedelmét. A probléma eredete, hogy a 70-es évek közepén az USA-ban indítottak egy drága RCT-t. Sorsolással döntöttek, ki kap képzést, ki boldogul egyedül a munkaerőpiacon, az RCT kimutatta a valós pozitív hatást. 1986-ban egy közgazdász vette ennek a National Supported Work program adatait, kidobta a kísérlet valódi kontrollcsoportját, helyette vett egy országos megfigyelésen alapuló adatbázist. Lineáris regresszióval próbálta kiszámolni a tréning valódi hatását, kezelt embereket átlag amerikaiakhoz hasonlítva, negatív hatást kapott. Az ellentmondás feloldása az volt, hogy a linkelt tanulmány szerzőpárosa logisztikus regressziót épített, hogy megbecsüljék, mekkora esélye (propensity score) lett volna egy átlag amerikainak arra, hogy bekerüljön a tréningbe, felhasználva a confoundereket (életkor, iskolai végzettség, korábbi jövedelem…). A nearest-neighbour matching módszerrel a tréningezett embert egy hasonló propensity score-ú átlagos amerikaival (a korábbi torzítást az okozta, hogy a tréningre az alacsonyabb társadalmi, kereseti percentilisekből mentek főleg, ez nem volt figyelembe véve). Miután a propensity score alapján kidobták a nem összehasonlítható embereket, a tréning

kimutatott hatása csak 1%-kal tért el az eredeti tanulmány kimutatott nagy pozitív hatásától.

2. Cikk: Morgan, S. L. (2001). *Counterfactuals, causal effect heterogeneity, and the Catholic school effect on learning.* Sociology of Education, 341–374.

Amerikában az volt a közmegegyezés, hogy a katolikus (magán) középiskolák jobb oktatást biztosítanak. A katolikus iskolába járó gyerekek kompetencia tesztjei magasan verték az állami iskolásokét. A politikusok ebből azt a következtetést vonták le, hogy az állami iskolák sokkal rosszabbak a magániskoláknál. Értelemszerűen ezt nem lehetett RCT-vel tesztelni. Egy gyerek nem véletlenül kerül magániskolába. A propensity score kiszámításához használt tényezők (socioeconomic status, középiskola előtti teszteredmények stb.) együttesen meghatározták, egy gyerek mekkora eséllyel köt ki egy katolikus iskolában. A szerző a logisztikus regresszióval kapott propensity score alapján nem átlagot vont (ATE), hanem sorba állította a diákokat PS alapján, és csoportokra bontotta őket. Ez a stratification matching. A high propensity csoport (tehetős szülők, egyetemi elvárások) egyéneire a magániskola hozzáadott értéke elhanyagolható volt. A low propensity csoport (szegény család, gyenge korábbi jegyek) tagjainak kis esélyük van fizetős iskolába jutni, azonban bejutás esetén a hatás kiemelkedően pozitív volt. Megmutatkozott a hatás heterogenitása.

3. Cikk: Gilligan, M. J., & Sergenti, E. J. (2008). *Do UN interventions cause peace? Using matching to improve causal inference.*

Az ENSZ békefenntartás kapcsán a naiv statisztikák azt mutatták, hogy ahol az ENSZ jelen van, ott hamarabb kiújul a háború. Ebből politikusok azt szűrték le, hogy a késisakosok inkompetensek. A szerzők vettek 117 polgárháborút, és logisztikus regresszióval kiszámolták, mekkora valószínűséggel menne oda az ENSZ (confounderek: konfliktus hossza, ország megosztottsága, háború előtti halálesetek száma). A propensity score matching után, mikor az ENSZ missziókat kizárólag magukra hagyott, de *ugyanolyan véres* háborúkkal hasonlították össze, kiderült, hogy az ENSZ beavatkozással a béke átlagosan sokkal tovább tart. Common support által ahol nem volt ENSZ, tele volt könnyen megoldható esetekkel. Ahol volt ENSZ, ott ilyen esetekből nem volt, mert ilyenkor nem avatkozik be, ekkor a PSM ezeket az eseteket kidobta, nem használta számításhoz.

4. Szimuláció és eredmények

[TODO: Adatgeneráló folyamat 1: a propensity score jól előrejelzi a kezelést, a confounder torzítása kiszűrődik, az ATE becslése jó (naiv különbség vs. PSM, kiegyensúlyozottsági ellenőrzés).]

[TODO: Adatgeneráló folyamat 2: a propensity score gyengén jelzi előre a kezelést (pl. kimaradó confounder, rosszul specifikált modell, gyenge overlap), így a becslés torzított marad.]

5. Következtetések és limitációk

[TODO: Feltételek, amelyek mellett a PSM működik; limitációk (megfigyelhetetlen confounder, overlap hiánya, modellspecifikáció, matching-paraméterek); lehetséges általánosítások.]

Hivatkozások

[1] Dehejia, R. H., & Wahba, S. (1999). Causal effects in nonexperimental studies: Reevaluating the evaluation of training programs. *Journal of the American Statistical Association*, 94(448), 1053–1062.

[2] Gilligan, M. J., & Sergenti, E. J. (2008). Do UN interventions cause peace? Using matching to improve causal inference. *Quarterly Journal of Political Science*, 3(2), 89–122.

[3] LaLonde, R. J. (1986). Evaluating the econometric evaluations of training programs with experimental data. *American Economic Review*, 76(4), 604–620.

[4] Morgan, S. L. (2001). Counterfactuals, causal effect heterogeneity, and the Catholic school effect on learning. *Sociology of Education*, 74(4), 341–374.

[5] Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41–55.